

INFORME FINAL DE RESULTADOS EXPERIMENTALES

Comparación entre un VAE no equivariante y un VAE
equivariante continuo $SO(2)$ para histopatología

Proyecto de tesis
Maximiliano Garavito Chtefan
Universidad Industrial de Santander

9 de septiembre de 2026

1. Resumen ejecutivo

Este informe responde las solicitudes de evaluación registradas por el profesor en los issues #2, #3, #4 y #6: curvas y gráficas de resultados, MAE, MSE, PSNR, SSIM, desviación estándar, tamaño muestral, diagramas de caja, 25 reconstrucciones fijas, rotaciones de 90/180/270 grados y una visualización PCA del espacio latente para ambos modelos.

Conclusión principal. La evidencia completa es mixta y no permite declarar un ganador universal.

- Reconstrucción sellada: el VAE no equivariante obtuvo un MAE promedio ligeramente menor. La diferencia primaria normal menos SO(2) fue -0,001358, pero su IC 95% por bootstrap de WSI [-0,002213; 0,000046] incluye cero; no se estableció una diferencia.
- Diagnóstico WSI: SO(2) fue numéricamente mejor en F1 macro (0,483 frente a 0,389) y exactitud (0,609 frente a 0,522), pero el IC 95% de la diferencia de F1 macro también incluye cero.
- Tejido: SO(2) tuvo un F1 macro numéricamente mayor en los cuatro presupuestos bajos; solo 500 etiquetas por clase tuvo un intervalo simultáneo que excluye cero. El área global bajo la curva de aprendizaje (AULC) fue inconclusa y, en el presupuesto máximo, el modelo normal tuvo mayor F1 macro.
- Geometría rotacional post-hoc: se reprodujo y corrigió un cambio de signo que unía orientaciones opuestas en 90 y 270 grados. El aparente patrón previo queda retirado. A 1 grado, SO(2) tuvo menor razón de linealidad local normalizada por la entrada en 25/25 parches (medianas 0,601 frente a 0,649), pero el efecto fue 7,38% y no sobrevivió la robustez preespecificada: a 5 grados solo ocurrió en 8/25. No se demostró una acción reducida compartida ni una factorización local contenido--pose.
- Acción en el decodificador: al transformar espacialmente el embedding final antes de decodificar, SO(2) redujo el error frente al VAE normal en 25/25 parches para el barrido de 5 grados. En rotaciones exactas de 90, 180 y 270 grados, su razón de acción fue 0,000002 frente a 0,709 normal. Esto verifica empíricamente una acción C4 compartida y sin parámetros ajustados en el decodificador de este checkpoint; no prueba equivarianza continua del encoder ni factorización contenido--pose.

Lectura para la presentación

Pregunta	Respuesta respaldada
¿Reconstruye mejor SO(2)?	No. El modelo normal es ligeramente mejor en promedio, sin diferencia primaria establecida.
¿Ayuda en tareas posteriores?	Hay señales favorables a SO(2) en WSI y en bajo etiquetado, pero no una superioridad general.
¿La equivarianza es visible?	Sí en el decodificador para rotaciones exactas C4: transformar el embedding rota la reconstrucción de SO(2) casi exactamente. No se verificó una acción continua compartida en μ ni campos F1 limpios.
¿Falta experimentar?	Los issues quedan respondidos. La geometría nueva es validación fija exploratoria y no justifica afirmar un producto global o disentanglement.

2. Pregunta experimental y comparación

Se compararon dos codificadores variacionales entrenados sobre el mismo dominio histopatológico: una línea base convolucional no equivariante y una arquitectura con equivarianza continua SO(2). Ambos completaron 60.000 actualizaciones. Las particiones, los checkpoints y el cierre del entrenamiento precedieron al test; sin embargo, la agregación exacta y el bootstrap de reconstrucción se formalizaron después de abrir las etiquetas de los tests posteriores. Esos resultados no se usaron para cambiar modelos ni seleccionar checkpoints.

Propiedad	VAE no equivariante	VAE equivariante SO(2)
Simetría arquitectónica	Sin restricción rotacional explícita	Equivarianza continua SO(2)
Actualizaciones	60.000	60.000

Propiedad	VAE no equivariante	VAE equivariante SO(2)
Parámetros aprendibles	3.958.435	1.180.035
Tamaño relativo	100%	29,8% del modelo normal

La reducción aproximada de 70,2% en parámetros es relevante para eficiencia, pero también es una limitación causal: la comparación cambia simultáneamente la simetría y la capacidad del modelo.

Implementación SO(2) verificada antes del experimento

La implementación continua SO(2) fue validada por componentes y como VAE completo antes del entrenamiento sobre datos reales. Esta verificación responde la parte de implementación del issue #6.

Componente	Evidencia de verificación
No linealidades y normalización	34 compuertas radiales F0/F1 y 40 normalizaciones: aritmética FP32, gradientes y actualizaciones finitas.
Remuestreo y upsampling	Seis downsamplers y seis upsamplers fijos; formas 256-128-64-32 y 32-64-128-256 verificadas.
Muestreo VAE y estadísticas latentes	μ , $\log \sigma$, z con epsilon controlado, decodificador y reconstrucción comprobados en ángulos cardinales y no cardinales; μ tiene forma (B,16,32,32).
Referencia y runtime	escnn se usó solo como oráculo de pruebas focalizadas; no es dependencia del runtime. La implementación propia compilable pasó el prelaunch batch-25 dual T4 sin skips AMP ni recompilaciones.

3. Protocolo de evaluación

Capa de evidencia	Población	Unidad	Uso
Validación fija	25 parches predeterminados	Parche	Descripción y control visual; no es test sellado
Reconstrucción sellada	67.138 parches de 23 WSI	Parche; bootstrap por WSI	Comparación primaria de MAE y endpoints secundarios
Diagnóstico WSI sellado	23 WSI	WSI	F1 macro, exactitudes y entropía cruzada
Tejido sellado	31.572 parches de 23 WSI	Parche; remuestreo por WSI	Eficiencia de etiquetas en cinco presupuestos

Regla de inferencia. En reconstrucción, MAE normalizado fue el endpoint confirmatorio. MSE, PSNR y SSIM fueron secundarios. Las desviaciones estándar de parches describen dispersión y no sustituyen los intervalos de incertidumbre por WSI.

Dirección de contrastes. Salvo que se indique lo contrario, las diferencias se informan como normal menos SO(2): valores negativos favorecen al modelo normal en errores (MAE/MSE) y favorecen a SO(2) en métricas donde un valor mayor es mejor (F1/exactitud).

4. Entrenamiento y validación fija de 25 parches

La validación fija permite comprobar convergencia, estabilidad y calidad visual con exactamente los mismos parches para ambos modelos. Sus resultados son descriptivos; no reemplazan la evaluación sellada.

Normal VAE vs continuous SO(2) VAE — archived training evidence

Train display smoother: centered 501-counter mean • validation markers: 30,000 patches • fixed metrics: 25 patches



X-axis: recorded successful-update counter. Normal counter 14,007 is the disclosed accepted physical-skip event.


Figura 1. Panel de entrenamiento hasta 60.000 actualizaciones: objetivo, Charbonnier/L1, 1-SSIM, PSNR, diagnóstico latente de equivarianza y tasa de aprendizaje. Validación fija de 25 parches; no es test sellado.

Métrica	Normal: media (DEp)	SO(2): media (DEp)	n
MAE (menor es mejor)	0.0608 (0.0127)	0.0624 (0.0130)	25 / 25
MSE (menor es mejor)	0.0071 (0.0028)	0.0075 (0.0029)	25 / 25
PSNR dB (mayor es mejor)	27.898 (1.839)	27.645 (1.826)	25 / 25
SSIM (mayor es mejor)	0.7308 (0.0637)	0.7170 (0.0637)	25 / 25

En esta muestra descriptiva, el modelo normal tuvo menor MAE/MSE y mayor PSNR/SSIM. No se aplicó inferencia estadística a la validación fija.

Reconstruction metrics — fixed validation 25

Same 25 predetermined patches for both models • raw paired observations + population summaries



Boxes: Q1-Q3; center: median; whiskers: observed min/max; every paired raw point is shown.


Fixed-25 validation only — not a full-validation distribution or sealed-test comparison.

Figura 2. Diagramas de caja solicitados para MAE, MSE, PSNR y SSIM en los 25 parches fijos. Cada caja resume $n=25$ por modelo; DEp significa desviación estándar poblacional.

5. Reconstrucciones cualitativas fijas

Las reconstrucciones permiten verificar que ambos modelos preservan estructura y color generales. La inspección visual complementa, pero no reemplaza, las métricas cuantitativas.

Final reconstructions — same predetermined fixed validation 25



Ordered by frozen selector rank (five patches per source histotype); FP16 archives shown after $[-1,1] \rightarrow [0,1]$ clamping.

Figura 3. Originales y reconstrucciones de los 25 parches predeterminados para ambos modelos. Población: validación fija; $n=25$; selección fijada antes del análisis.

Cómo leer esta figura

- Buscar pérdida de bordes celulares, suavizado excesivo, cambios de color y artefactos repetitivos.
- No elegir un modelo por un parche aislado: las métricas selladas agregan 67.138 parches.
- La selección fija evita escoger ejemplos favorables después de observar los resultados.

6. Reconstrucción en el test sellado

La evaluación principal amplió la comparación a 67.138 parches procedentes de 23 WSI. Los intervalos se calcularon con 10.000 remuestras por conglomerado WSI; cubren variación entre WSI, no nuevas semillas de entrenamiento ni una nueva selección de parches.

Métrica	Normal: media (DEp)	SO(2): media (DEp)	Normal - SO(2)
MAE	0.0629 (0.0239)	0.0642 (0.0223)	-0.0014
MSE	0.0080 (0.0074)	0.0083 (0.0067)	-0.0003
PSNR (dB)	27.923 (2.721)	27.658 (2.595)	+0.264
SSIM	0.7575 (0.0842)	0.7436 (0.0862)	+0.0139

Resultado primario. MAE: 0,062872 para el modelo normal y 0,064230 para SO(2). Diferencia normal menos SO(2) = -0,001358; IC 95% [-0,002213; 0,000046]. Como el intervalo incluye cero, no se estableció una diferencia de reconstrucción primaria.

Endpoints secundarios. PSNR y SSIM favorecen descriptivamente al modelo normal, y sus intervalos exploratorios no cruzan cero. Se mantienen como resultados secundarios: no sustituyen la conclusión del endpoint primario.

Full sealed test descriptive patch distributions

Boxes describe correlated patches; they are not confidence intervals




Figura 4. Distribuciones por parche en el test sellado: 67.138 parches por modelo, agrupados en 23 WSI. Las cajas describen dispersión de parches; no son intervalos inferenciales. La tabla superior proporciona la escala numérica.

7. Consistencia entre WSI

La vista pareada por WSI evita que el gran número de parches oculte la unidad biológica. En 22 de los 23 WSI, el MAE medio del modelo normal fue menor; un WSI mostró el patrón contrario. Aún así, la incertidumbre del estimando primario ponderado por parches alcanza el cero.




Figura 5. MAE medio pareado por WSI en el test sellado (n=23 WSI). Cada línea conecta exactamente el mismo WSI bajo ambos modelos.

Interpretación

El patrón por WSI sugiere una pequeña ventaja de fidelidad para el modelo normal, coherente con los endpoints secundarios. Sin embargo, el objetivo del experimento no era optimizar solo píxeles: también se evaluó si las representaciones resultaban útiles para diagnóstico y tejido.

8. Geometría de la acción rotacional en el espacio latente


Este análisis es un trabajo post-hoc, exploratorio y exclusivo de los 25 parches fijos de validación. No accedió al test sellado, no reentrenó los VAE y no cambió checkpoints. Su pregunta principal no fue si cada parche dibuja un ciclo —resultado casi trivial para un codificador continuo— sino si una misma acción rotacional reducida transfiere entre parches y permite separar aproximadamente contenido y pose.

Control exacto a cuartos de vuelta

La comparación solicitada originalmente a 90, 180 y 270 grados usa exclusivamente `torch.rot90` y permanece válida. La figura conserva el parche predeterminado de rango 12 y compara reconstruir la entrada rotada con transformar espacialmente el latente antes de decodificar.

Rotated input vs transformed latent — predetermined fixed patch

selector rank 12 • validation:00028360:59031:2:44544:9984 • exact quarter turns



Annotations are normalized-domain MAE. 0° paths coincide by definition; this is fixed validation, not sealed test.

Figura 6. Comparación cualitativa a 0, 90, 180 y 270 grados: verdad objetivo, reconstrucción de la entrada rotada y reconstrucción después de transformar el latente. n=1, selector rank 12 del fixed-25; no es resultado poblacional ni test sellado.

Resultado cuantitativo complementario

En el único parche mostrado, la diferencia MAE entre las dos rutas de decodificación fue 0,1002/0,1097/0,0988 para el VAE normal y 0,0118/0,0130/0,0109 para SO(2) a 90/180/270 grados. Esto respalda una mayor consistencia entre rutas en ese ejemplo, pero n=1 impide generalizarlo.

En el proxy enmascarado de residuo latente para los 25 parches, menor es mejor. Las medianas aceptadas fueron 1,327492/1,303358/1,326518 para el modelo normal y 1,472552/1,417673/1,486783 para SO(2). Este control exacto no favorece a SO(2) en la salida posterior final.


Acción decodificada y comparación pareada

El experimento complementario de Spec 0051 evaluó dos rutas sobre los mismos 25 parches. La razón de acción compara $D(\rho_T \mu(x))$ con $T D(\mu(x))$; la razón de canonicalización compara $D(\rho_T^{-1} \mu(Tx))$ con $D(\mu(x))$. Cada denominador es el error de dejar el embedding sin la transformación correspondiente. Por tanto, 1,00 representa la línea base de no actuar y 0,50 exige conservar como máximo la mitad de ese error. Este 0,50 es un criterio funcional absoluto fijado antes de ver la salida; no decide qué VAE es mejor. La comparación entre modelos es pareada sobre los mismos parches y se resume también por sus 16 WSI de origen.

En el barrido 0, 5, ..., 355 grados, SO(2) tuvo menor error que el modelo normal en 25/25 parches y 16/16 medianas por WSI. La razón de acción mediana fue 0,550 SO(2) frente a 0,713 normal, una reducción relativa de 22,88%; la diferencia pareada SO(2) menos normal por bootstrap descriptivo de WSI fue -0,150 [-0,163; -0,124]. Para canonicalización, las medianas fueron 0,513 frente a 0,661, reducción de 22,33%, con diferencia -0,156 [-0,177; -0,128]. El conjunto constituye una ventaja comparativa consistente de SO(2) en la consistencia de rutas decodificadas. H1 y H2 completos permanecen no respaldados porque sus reglas conjuntivas exigían además una mediana SO(2) $\leq 0,50$; ambos valores quedaron ligeramente por encima. Ese criterio absoluto no anula la comparación pareada.

Consistencia decodificada en los 25 parches fijos

Comparación pareada normal vs. SO(2) · rotaciones 0°, 5°, ..., 355°



Razón 1,00 = no actuar · línea gris discontinua: criterio absoluto 0,50 = conservar como máximo la mitad del error.

Figura 6a. Razones pareadas de acción espacial y canonicalización decodificadas para los 25 parches fijos de validación, con rotaciones 0, 5, ..., 355 grados. Cada línea une el mismo parche. SO(2) es menor en 25/25 pares en ambas métricas. El eje parte de cero y la línea gris discontinua marca el criterio funcional absoluto 0,50; los intervalos resumen primero por WSI y remuestran las 16 WSI, sin inferencia poblacional.

El resultado exacto es mucho más fuerte. Agregando 90, 180 y 270 grados, la razón de acción fue 0,00000218 SO(2) frente a 0,709453 normal, con error absoluto numéricamente cercano a cero y señal de pose no nula. La canonicalización decodificada fue 0,088854 frente a 0,710638. Así, el decodificador SO(2) realiza numéricamente la misma acción espacial C4 para todos los parches fijos, sin ajustar parámetros por parche. Esto reconcilia la observación visual con el residuo desfavorable de μ : el posterior crudo no coincide mejor bajo ese proxy, pero las dos rutas convergen después de decodificar. El experimento no identifica un espacio nulo del decodificador.

Los ángulos no cardinales siguen siendo aproximados: al excluir vecindades de 5 grados alrededor de los cardinales, las razones SO(2) suben a 0,568 para acción y 0,524 para canonicalización. Además, la ruta completa $D(\mu(Tx))$ frente a $T D(\mu(x))$ favoreció al VAE normal en 25/25 parches, con medianas 0,174 normal y 0,210 SO(2). Por ello, el hallazgo no equivale a una superioridad general del encoder o del autoencoder.

En los cuatro flips exactos, SO(2) tuvo razones descriptivamente menores, pero sólo la reflexión respecto a la diagonal principal cumplió simultáneamente los criterios de entrada, acción y canonicalización. Las reflexiones horizontal, vertical y antidiagonal no pasaron. No se demostró equivarianza completa D4 ni O(2).

Transformaciones exactas en la cuadrícula

Medianas sobre 25 parches · C4 y cuatro reflexiones




Figura 6b. Medianas de acción latente, canonicalización y conmutación de entrada a salida para las siete transformaciones no identidad del grupo D4 exacto. Las rotaciones R90/R180/R270 muestran la acción C4 casi exacta del decodificador SO(2). Entre los flips, sólo Fd cumple la regla completa para ese checkpoint. La línea gris discontinua marca el criterio absoluto 0,50; n=25 parches fijos de validación.

En estas métricas, los objetivos son transformaciones de la reconstrucción producida por cada modelo, no imágenes originales independientes. El análisis evalúa consistencia entre rutas de transformación y decodificación; no reemplaza las métricas selladas de fidelidad de reconstrucción.

Defecto de convención, reparación y alcance

El barrido denso anterior mezclaba dos convenciones: los múltiplos de 90 grados usaban la orientación positiva de `torch.rot90`, mientras que la matriz afín no cardinal convergía a la orientación opuesta. Al unir puntos consecutivos aparecían los segmentos rectos observados cerca de 90 y 270 grados. Esa evidencia, incluidas las Figuras 7, 8a y 8b anteriores y la afirmación universal 25/25, queda explícitamente supersedida.

La reparación usa una sola interpolación bilineal continua en todo el ciclo 0--359 y reserva `torch.rot90` como control independiente. Fixtures asimétricos de impulso, flecha y borde dieron error cardinal exactamente cero en CPU y GPU; el RMS máximo a ambos lados de un cardinal fue 0,00000520, el error máximo de orientación 0,0193 grados y los errores de inversión/composición quedaron por debajo de 0,024, atribuibles a interpolación. En el parche 12, los pasos RMS de entrada 87--88, 88--89, 89--90, 90--91 y 91--92 fueron 0,1011/0,1025/0,1118/0,1129/0,1035: desapareció el salto previo de aproximadamente 0,24.

Órbitas por parche y ausencia de acción reducida





Figura 7. Geometría PCA local corregida de los rangos 0 y 12, elegidos antes de ver la salida. Cada parche y modelo usa coordenadas propias; signos, ejes y escalas no se comparan entre paneles. En los 25 parches fijos, las seis primeras PC capturan medianas de solo 11,09% normal y 10,86% SO(2), de modo que estas proyecciones son descriptivas.

La PCA de una órbita completa estima un subespacio lineal que contiene variación rotacional; no identifica por sí sola el vector tangente ni una acción común. Los tangentes de órbita necesitaron medianas de 120/114 dimensiones para explicar 90% de su variación (normal/SO(2)), y los subespacios locales entre parches fueron casi ortogonales. No apareció un plano tangente crudo compartido de baja dimensión.

Los mosaicos siguientes muestran los 25 ciclos ya corregidos. No se seleccionaron ejemplos por apariencia: se fijaron los rangos 0 y 12. Cada panel ajusta una PCA local con ejes isótropos; las métricas se calcularon sobre μ crudo dentro del disco latente de radio 14, no sobre la proyección.

Órbitas latentes de los 25 parches fijos

Parte A · parches 00--14 · muestreo cada 1°




Cada curva contiene 360 posiciones (0°--359°); la escala es isótropa y propia de cada panel.

Figura 8a. Órbitas corregidas de los parches fijos 00--14 a intervalos de 1 grado. Los segmentos largos espurios de la versión anterior ya no aparecen. Cada par usa una PCA propia y escala isótropa.

Órbitas latentes de los 25 parches fijos

Parte B · parches 15--24 · muestreo cada 1°



Cada curva contiene 360 posiciones (0°--359°); la escala es isótropa y propia de cada panel.

Figura 8b. Órbitas corregidas de los parches fijos 15--24 a intervalos de 1 grado. La forma puede compararse dentro de cada panel, no como un sistema de coordenadas común entre parches o modelos.

Regularidad y controles de la trayectoria de entrada

A 1 grado, la razón de linealidad local normalizada por la entrada fue menor para SO(2) en 25/25: medianas 0.601 frente a 0.649 normal, una reducción relativa de 7,38%. El intervalo bootstrap descriptivo de la mediana pareada SO(2) menos normal fue [-0.051; -0.046]. Sin embargo, el umbral preregistrado exigía al menos 10% y robustez de escala: a 5 grados SO(2) fue menor sólo en 8/25 y las medianas se invirtieron ligeramente (1.033 frente a 1.032). H1 no pasó.

El CV crudo del paso a 1 grado favoreció al modelo normal: medianas 0.0125 normal y 0.0167 SO(2), con SO(2) menor en sólo 3/25. Tras normalizar por el recorrido de entrada, la comparación cambió a 0.0181/0.0164 y 18/25. La dependencia de resolución, normalización e interpolación impide afirmar una ventaja general de regularidad.




Figura 8c. Métricas de los 25 parches fijos y controles de la trayectoria de entrada para 1, 2 y 5 grados, con y sin vecindades cardinales. La mejora descriptiva a 1 grado no superó el criterio preregistrado ni fue robusta a 5 grados.

Organización armónica y campos internos F1

La fracción mediana de la energía orbital cruda total capturada por $m=1, \dots, 6$ dentro de PC1--PC6 fue 0.107 normal y 0.106 SO(2); SO(2) fue mayor en sólo 9/25. El número efectivo de frecuencias fue 4.135/3.982; la reducción de SO(2), aunque presente en 18/25, fue 3,7%, por debajo del 10% fijado. H2 no pasó y las seis PC sólo capturan cerca de 11% de la variación total.




Figura 8d. Energía armónica de PC1--PC6 para los ejemplos preseleccionados. Las escalas de color son internas a cada panel; múltiples frecuencias pueden surgir legítimamente al rotar textura espacial. No apareció una concentración SO(2) específica robusta.

Antes de `mu_head`, la arquitectura contiene 48 copias F0 y 48 copias F1; la salida posterior `mu` contiene 16 campos espaciales F0 y ninguna copia F1 explícita. Se midieron las 48 F1 mediante vectores complejos promediados y, para evitar cancelación espacial, mediante el campo completo compensando rotación interna y de coordenadas. Ninguna de las 48 cumplió simultáneamente pureza $m=1$, pendiente de fase, amplitud y residuo; el residuo completo mediano por parche fue 1,906 y el RMSE de fase mediano 1,671 radianes. H3 no pasó. Esto no invalida la construcción del tipo de campo, pero impide afirmar que el checkpoint entrenado verificó esa ley empíricamente.




Figura 8e. Diagnóstico de las 48 copias internas F1. Resultado: 0/48 copias limpias bajo los umbrales fijados; el residuo de campo completo confirma que la fase inestable no se explica únicamente por cancelación del promedio espacial.

Acción compartida y factorización

La partición derivada de hashes fijó 17 parches para ajuste y 8 para evaluación; se ajustó con ángulos múltiplos de 5 grados y se evaluaron los demás. Entre $d=1, \dots, 6$, la regla fijada seleccionó $d=1$, que es necesariamente una acción ortogonal continua nula. En held-out, el NRMSE/R2 fue 1,420/-1,017 normal y 1,450/-1,103 SO(2); ningún parche (0/8 en ambos modelos) mejoró frente a identidad. Incluso $d=6$ capturó sólo 0,15%/0,24% de la varianza held-out. Por tanto, H4 no pasó y no se demostró una acción reducida compartida. La ley de grupo casi exacta de $\exp(\theta A)$ es una propiedad numérica impuesta por la parametrización, no evidencia de que A prediga las órbitas.




Figura 8f. Rendimiento held-out del generador compartido frente a dimensión. La dimensión seleccionada fue $d=1$, línea base nula; ninguna dimensión mostró una ventaja específica de SO(2) sobre identidad o el control de ángulos barajados.

La acción espacial conocida sobre mu también tuvo residuos altos: medianas 1.675 normal y 1.668 SO(2), con 0/25 por debajo del umbral 0,25. Su canonicalización redujo la varianza intraórbita a cerca de 0,34 de la identidad, pero aumentó la varianza entre parches unas 4,7--4,8 veces; W/B quedó en 3,235 normal y 3,344 SO(2). Como esa acción espacial sobre mu no fue verificada, la reducción no respalda separación contenido--pose. Con la acción aprendida $d=1$, canonicalizar equivale exactamente a identidad y los probes de ángulo no mejoran. H6 queda no resuelta —no apoyada—, no rechazada.




Figura 8g. Canonicalización mediante la acción espacial conocida y la acción reducida aprendida. La conocida no satisface el residuo de equivarianza y la aprendida coincide con identidad; no hay evidencia válida de factorización local.

Interpretación geométrica

Nivel	Qué significa aquí	Resultado
Órbita por parche	Curva de μ al rotar una imagen	Continua tras reparar el operador; evidencia descriptiva
Acción espacial C4 prescrita	La arquitectura prescribe ρ ; se prueba su conmutación con el decoder	Verificada empíricamente en 25/25 para R90, R180 y R270
Acción reducida aprendida	Un mismo $\exp(\theta A)$ predice parches y ángulos nuevos	No demostrada
Factorización local	$Q(-\theta)$ estabiliza contenido sin borrar diferencias	No apoyada; no resuelta sin acción reducida válida
Producto global	Un $SO(2) \times \mathbb{R}^n$ único sobre toda la representación	Fuera de alcance e imposible de concluir con 25 parches

Prescrito por arquitectura: existen tipos F0/F1 y una acción espacial candidata ρ . Verificado empíricamente: el operador de entrada corregido y la conmutación casi exacta del decodificador del checkpoint $SO(2)$ con C4 en 25/25; no la equivarianza continua del encoder. Observado en el checkpoint entrenado, sin atribución causal: la ventaja comparativa en consistencia de rutas decodificadas para ángulos interpolados, junto con órbitas crudas complejas y de alta dimensionalidad. Transferencia entre parches: la acción espacial C4 no usa parámetros por parche, pero ninguna acción reducida aprendida superó identidad. Lectura tipo fibrado: la canonicalización decodificada bajo giros C4 exactos fue fuerte, pero no exacta, y no define un cociente de contenido ni fases locales fiables; una interpretación de fibras, gauges o topología permanece especulativa.

9. Visualización PCA del espacio latente

La visualización tipo EQ-VAE proyecta descriptores latentes espaciales a tres componentes principales y los presenta como falso color. Su propósito es mostrar organización espacial dentro del latente; PCA es un sistema de coordenadas, no una métrica de calidad ni de equivarianza.




Figura 9. Visualización PCA-RGB de cuatro parches mostrados (ranks 0, 8, 12 y 24) de la fuente fixed-25. Los modelos usan ajustes PCA separados; los colores y rangos no deben compararse como magnitudes absolutas entre modelos.

La coherencia local mediana r_{edge} fue 1,4567 para el modelo normal y 1,4676 para SO(2); menor es más coherente bajo este proxy. La diferencia no respalda una ventaja de coherencia local para SO(2). Un lector RGB local exploratorio también obtuvo $R^2=0,286$ para normal y $R^2=0,189$ para SO(2). Ninguno de estos diagnósticos es un endpoint confirmatorio.

10. Diagnóstico WSI en el test sellado

Desarrollo supervisado y selección

Los clasificadores se ajustaron después de congelar cada representación. En MIL se usaron 106 WSI de entrenamiento y 23 WSI de validación; ambos entrenamientos terminaron por parada temprana. La pérdida de train se registró en línea antes de cada actualización y se resume por ventanas de 53 actualizaciones, una WSI por actualización, mientras que el F1 y la entropía cruzada de validación se calcularon con el modelo fijo en cada frontera. Para tejido se entrenó un clasificador por representación y presupuesto con subconjuntos balanceados. La validación sirvió para seleccionar checkpoints y no se reutiliza como evidencia del test sellado.

Desarrollo de los clasificadores supervisados

F1 de selección y brecha train-validación; el test sellado permanece separado




Figura 10. Desarrollo supervisado. Arriba izquierda: F1 macro de validación MIL; los puntos resaltan los checkpoints seleccionados (0,448 normal en la actualización 3.127 y 0,591 SO(2) en 5.671). Arriba derecha: entropía cruzada de train registrada en línea y promediada por cada ventana de 53 actualizaciones, junto con la entropía cruzada de validación en cada frontera. Como el modelo cambia dentro de cada ventana, la curva de train diagnostica la optimización y no equivale a evaluar un checkpoint fijo sobre todo train. Abajo: mejor F1 macro de validación tisular por presupuesto. Ningún panel es test sellado ni variación entre semillas.

Resultado WSI sellado

Se entrenó una única trayectoria de clasificador MIL por representación y se evaluó una sola vez sobre 23 WSI sellados. La tarea contiene cinco diagnósticos; LGSC y MC tienen solo dos WSI cada uno, por lo que las conclusiones por clase son frágiles.

Métrica	Normal	SO(2)	Normal - SO(2) [IC 95%]
F1 macro	0.389	0.483	-0.095 [-0.207; +0.050]
Exactitud balanceada	0.510	0.503	+0.007 [-0.167; +0.180]
Exactitud	0.522	0.609	-0.087 [-0.217; +0.043]
Entropía cruzada	1.323	0.993	+0.330 [+0.135; +0.524]

Diagnóstico WSI en el test sellado




Figura 11. Métricas de diagnóstico WSI en el test sellado (n=23 WSI). SO(2) es numéricamente mayor en F1 macro y exactitud; la diferencia de F1 macro no está establecida porque su IC 95% incluye cero.

La entropía cruzada, endpoint secundario, fue menor para SO(2) y su intervalo pareado favorece a SO(2). Este resultado debe interpretarse junto con el único entrenamiento del clasificador, el test pequeño y el bajo soporte de dos clases.

Desglose por clase en diagnóstico WSI

Las matrices permiten ver que la diferencia global no se distribuye uniformemente. SO(2) obtuvo F1 mayor en CC, EC, HGSC y LGSC, mientras que el modelo normal obtuvo F1 mayor en MC. En particular, el VAE normal no recuperó casos EC ni LGSC y SO(2) no recuperó MC. Estas observaciones son descriptivas: los soportes por clase son CC=5, EC=6, HGSC=8, LGSC=2 y MC=2 WSI.

Diagnóstico WSI: errores y F1 por clase

Test sellado: n=23 WSI; las celdas muestran conteo y porcentaje dentro de la clase real




Figura 12. Matrices de confusión normalizadas por clase real y F1 por diagnóstico en el test sellado. Cada celda incluye conteo y porcentaje dentro de su fila; los soportes 5/6/8/2/2 muestran por qué LGSC y MC no permiten conclusiones estables por clase.

Atribución espacial a parches

No se incluyó un mapa de atención por WSI porque la corrida sellada almacenó logits, predicción, tamaño de bolsa e identidad y resumen del grafo, pero no compuertas por parche. La atención local describe intercambio entre vecinos; las compuertas sigmoideas del resumen global no son probabilidades ni atribuciones causales o específicas de clase. Generar un mapa exige una nueva inferencia instrumentada sobre latentes y pesos congelados y, para superponerlo sobre tejido real, acceso al thumbnail o WSI. Un análisis futuro debería preseleccionar el WSI antes de inspeccionar el mapa, usar la misma escala espacial para ambos modelos y etiquetar el resultado como intensidad de lectura interna o sensibilidad post-hoc, no como explicación causal.

11. Eficiencia de etiquetas en tejido

La prueba de tejido usó 31.572 parches de 23 WSI: 21.796 tumorales, 8.500 de estroma y 1.276 de necrosis. La necrosis aparece en solo cinco WSI. Se compararon cinco presupuestos de etiquetas por clase con intervalos simultáneos para controlar la familia de contrastes. El bootstrap se estratificó por soporte tisular observado: 2 WSI con solo tumor, 16 con tumor y estroma, y 5 con los tres tejidos.

Etiquetas/clase	F1 macro normal	F1 macro SO(2)	Normal - SO(2), IC simultáneo 95%
250	0.508	0.523	-0.015 [-0.072; +0.041]
500	0.511	0.575	-0.064 [-0.121; -0.008]
1.000	0.582	0.598	-0.016 [-0.072; +0.041]
2.500	0.701	0.714	-0.013 [-0.069; +0.044]
5.671	0.766	0.710	+0.055 [-0.001; +0.112]

Eficiencia de etiquetas en tejido: F1 macro




Figura 13. Curvas de F1 macro por presupuesto en el test sellado de tejido: 31.572 parches de 23 WSI. Solo 500 etiquetas por clase presenta un intervalo simultáneo que excluye cero y favorece a SO(2).

Resumen global. La AULC trapezoidal normalizada sobre $\log_{10}(\text{etiquetas por clase})$, sin suavizado, fue 0.615 para normal y 0.631 para SO(2). Diferencia normal menos SO(2) = -0.016; IC simultáneo 95% [-0.073; +0.040]. El intervalo incluye cero: la ventaja global es inconclusa. Esta AULC resume el F1 macro medio en el rango logarítmico preespecificado; no demuestra que un modelo necesite menos etiquetas.

Eficiencia de etiquetas: F1 por tipo de tejido

Test sellado: 31.572 parches de 23 WSI; puntos descriptivos por presupuesto




Figura 14. F1 por tipo de tejido a cada presupuesto de etiquetas. Son estimaciones puntuales descriptivas; la inferencia primaria simultanea se definió para F1 macro, no para seleccionar retrospectivamente una clase. Necrosis tiene 1.276 parches pero aparece en solo cinco WSI.

El desglose muestra que las diferencias cambian según tejido y presupuesto. SO(2) presenta su señal más consistente en tumor a presupuestos bajos; estroma y, especialmente, necrosis fluctúan más. En el presupuesto máximo, la ventaja de F1 macro del modelo normal se explica en parte por un F1 de necrosis mayor. Esta lectura no convierte las curvas por clase en contrastes confirmatorios.

12. Síntesis integrada

Dimensión	Señal observada	Conclusión permitida
Fidelidad de reconstrucción	Normal ligeramente mejor	Sin diferencia primaria establecida
Diagnóstico WSI	SO(2) mayor en F1 macro y exactitud	Señal favorable, no superioridad general
Tejido con pocas etiquetas	SO(2) mayor en 250-2.500	Evidencia puntual a 500; AULC inconclusa
Presupuesto máximo de tejido	Normal mayor en F1 macro	El beneficio de SO(2) no persiste uniformemente
Geometría cruda de mu	Operador corregido; H1--H4 de Spec 0050 no pasan	Sin acción reducida aprendida ni factorización demostrada
Rutas decodificadas	SO(2) menor en 25/25; decoder C4 casi sin error	Ventaja comparativa de rutas y acción C4 del decoder; no SO(2) continuo
Eficiencia paramétrica	SO(2) usa 29,8% de parámetros	Ventaja de compactación; confusor de capacidad

Mensaje central para el profesor

La arquitectura continua SO(2) no mejoró automáticamente la reconstrucción ni mostró una acción reducida aprendida o una factorización demostrable en el posterior final. En el checkpoint SO(2) se observó una acción espacial C4 casi exacta al transformar el embedding antes del decoder y una reducción comparativa consistente del error entre rutas decodificadas para ángulos interpolados. El checkpoint también es mucho más compacto y presenta señales de utilidad en diagnóstico WSI y ciertos regímenes de bajo etiquetado; este estudio no aísla causalmente la simetría de la capacidad u otros factores. La conclusión responsable es específica por endpoint: se verificó empíricamente un mecanismo de rotación C4 en el decoder, mientras que la geometría cruda de mu y la separación contenido--pose siguen sin validarse.

13. Limitaciones

- Una sola trayectoria de entrenamiento por VAE y una sola trayectoria de clasificador por presupuesto: los intervalos no incluyen variación entre semillas de entrenamiento.
- El test WSI tiene 23 láminas; LGSC y MC solo aportan dos WSI cada una.
- El test de tejido contiene 31.572 parches, pero su incertidumbre efectiva depende de 23 WSI y la necrosis aparece en solo cinco.
- Los intervalos de tejido condicionan la inferencia a los estratos de soporte observados (2/16/5 WSI). Los cinco presupuestos comparten parches de test y datos de entrenamiento anidados, por lo que sus resultados están correlacionados.
- Los intervalos inferenciales sellados remuestran WSI y no cubren selección de parches, arquitectura ni nuevas semillas. En la geometría post-hoc, Spec 0050 remuestra los 25 parches pareados; Spec 0051 resume primero las diferencias por sus 16 WSI de origen y remuestra esas 16 WSI. Ambos intervalos son descriptivos y no poblacionales.
- Las desviaciones estándar por parche son dispersión descriptiva, no error estándar ni intervalo de confianza.
- SO(2) tiene aproximadamente 70,2% menos parámetros; simetría y capacidad no están aisladas como causas separadas.
- La geometría rotacional es post-hoc y exploratoria sobre 25 parches fijos de validación. No incorpora test sellado, variación entre semillas ni incertidumbre de una población nueva.
- La ventaja decodificada de Spec 0051 compara rutas dentro de cada modelo. Sus objetivos son transformaciones de la reconstrucción del propio modelo, no imágenes originales ni una nueva evaluación de fidelidad.
- La acción casi exacta se verificó en rotaciones de cuarto de vuelta alineadas con la cuadrícula. Los ángulos intermedios requieren interpolación y no sostienen la misma afirmación de exactitud; tampoco se evaluaron rotaciones continuas fuera de la rejilla de 5 grados.
- La interpolación bilineal impone parte de la regularidad de la trayectoria de entrada; las conclusiones dependen de controlar esa ruta y de la resolución angular. El efecto a 1 grado se invirtió a 5 grados.

13. Limitaciones (continuación)

- PC1--PC6 capturaron alrededor de 11% de la variación orbital. Los generadores de $d=1, \dots, 6$ examinan sólo una fracción pequeña del posterior espacial y no excluyen acciones compartidas de mayor dimensión o no lineales.
- La dimensión $d=1$ se eligió mediante una regla heurística de un error estándar leave-one-patch-out; los pliegues están correlacionados y la tolerancia no constituye incertidumbre poblacional.
- El addendum de revisión conserva ocho resultados por parche para el probe angular de factorización; aun así, la acción aprendida es identidad y los prerequisites no degenerados fallan, por lo que el estado es no resuelto.
- La evaluación WSI sellada no guardó compuertas por parche. Cualquier mapa espacial de lectura o atribución requiere una nueva inferencia instrumentada y una interpretación post-hoc separada.

14. Conclusiones para la presentación

- Los requerimientos de evaluación del profesor quedaron cubiertos para ambos modelos.
- La reconstrucción sellada no demuestra una diferencia primaria; el modelo normal conserva una ligera ventaja descriptiva.
- SO(2) ofrece compactación paramétrica fuerte y señales favorables en tareas posteriores, especialmente con 500 etiquetas por clase y en diagnóstico WSI, pero con incertidumbre y soporte limitado.
- El barrido corregido retira la anterior conclusión 25/25 como evidencia general: la diferencia descriptiva a 1 grado no alcanzó el umbral fijado y se invirtió a 5 grados.
- En las rutas decodificadas, SO(2) mostró una ventaja comparativa consistente para el barrido de 5 grados: menor error de acción y canonicalización en 25/25 parches. Sus medianas 0,550 y 0,513 no cumplieron el criterio funcional absoluto $\leq 0,50$, que es distinto de la comparación entre modelos.
- Para R90, R180 y R270 exactas se verificó empíricamente una acción espacial C4 compartida del decoder del checkpoint SO(2), con razón de acción agregada 0,00000218. El resultado no se extiende automáticamente a SO(2) continuo, al encoder ni al grupo D4 completo.
- No se demostró una acción rotacional reducida aprendida; la factorización local contenido--pose queda no resuelta y no se respalda una interpretación de producto global, fibrado o gauge con esta muestra.
- La contribución del experimento es mostrar dónde el checkpoint SO(2) presentó señales favorables, dónde no y dónde aparece una posible compensación descriptiva con la fidelidad de reconstrucción, sin atribución causal a un único componente arquitectónico.

Anexo A. Cobertura de lo solicitado por el profesor

Solicitud	Dónde se presenta	Estado
Gráficas de resultados de la línea base	Figuras 1-5	Completo
MAE, MSE, PSNR, SSIM	Secciones 4 y 6	Completo
Desviación estándar, n y boxplots	Tablas y Figuras 2 y 4	Completo
25 originales y reconstrucciones	Figura 3	Completo
Rotaciones 90/180/270	Figura 6	Completo
Órbita latente 0--359 y geometría local	Figura 7	Corregido; evidencia previa supersedida
Órbitas de los 25 parches cada 1 grado	Figuras 8a--8c	Corregido con controles de entrada
Armónicos y 48 campos F1	Figuras 8d y 8e	Completo; hipótesis no respaldadas
Acción compartida y factorización	Figuras 8f y 8g	Completo; acción reducida no demostrada
Rotar y desrotar el embedding decodificado	Figuras 6a y 6b; Sección 8	Completo; ventaja pareada y C4 exacto
Rotaciones y flips exactos D4	Figura 6b; Sección 8	Completo; sólo flip diagonal pasa en SO(2)
Visualización PCA espacial del latente	Figura 9	Completo
Repetir evaluación para SO(2)	Todas las tablas y figuras comparativas	Completo
Validar componentes SO(2)	Sección 2: no linealidades, normalización, upsampling, $\mu/\log\text{var}/z$ y runtime	Completo
Barrido continuo 0-359 grados	Sección 8: artefacto fijo-25 corregido	Completo; validación post-hoc
Utilidad posterior y desglose por clase	Figuras 10-14; Secciones 10 y 11	Completo
Atribución espacial WSI	Sección 10: frontera y protocolo futuro	Pendiente; requiere nueva inferencia

Anexo B. Definición breve de métricas

Métrica	Lectura
MAE	Error absoluto medio en dominio normalizado [-1, 1]; menor es mejor.
MSE	Error cuadrático medio en dominio normalizado [-1, 1]; menor es mejor.
PSNR	Relación señal-ruido pico en dB, imagen recortada a [0, 1]; mayor es mejor.
SSIM	Similitud estructural en imagen [0, 1]; mayor es mejor.
F1 macro	Promedio no ponderado del F1 de cada clase; valora por igual clases frecuentes y raras.
Exactitud balanceada	Promedio del recall por clase; reduce el predominio de las clases frecuentes.
Entropía cruzada	Pérdida probabilística; menor es mejor y penaliza predicciones confiadas incorrectas.
AULC	Área trapezoidal normalizada del F1 macro sobre log10(etiquetas por clase), sin suavizado; equivale al rendimiento medio en el rango logarítmico preespecificado y no demuestra necesitar menos etiquetas.
Razón de linealidad local	RMS cíclico de la segunda diferencia de μ dividido por el RMS cíclico de la primera; depende del paso angular y debe compararse con la trayectoria de entrada.
CV del paso angular	Desviación estándar dividida por la media de los pasos RMS cíclicos de μ entre ángulos consecutivos; menor indica velocidad de recorrido más uniforme.
Concentración armónica	Fracción de la energía orbital cruda total capturada por $m=1, \dots, 6$ dentro de PC1--PC6; una frecuencia limpia requiere además transferencia y suficiente varianza capturada.
NRMSE / R2 del generador	Predicción de ángulos y parches retenidos con una única acción $\exp(\theta_A)$; NRMSE menor y R2 mayor son mejores, siempre contra identidad y ángulos barajados.
Residuo de acción conocida	Norma relativa entre $E(R_{\theta_A} x)$ y la rotación espacial de $E(x)$ dentro del disco latente; cero representa equivarianza exacta.
Razón de acción decodificada	RMS entre $D(\rho_T \mu(x))$ y $T D(\mu(x))$, dividido por el error de dejar μ sin transformar. Uno es la línea base de no actuar; menor es mejor y 0,50 significa reducir ese error al menos a la mitad.
Razón de canonicalización decodificada	RMS entre $D(\rho_{T^{-1}} \mu(Tx))$ y $D(\mu(x))$, dividido por el error sin desrotar el embedding. Mide consistencia entre rutas, no fidelidad frente a la imagen original.
$F = W / B$	Varianza intraórbita después de canonicalizar dividida por varianza entre parches; sólo apoya factorización si la acción es válida, W disminuye y el contenido se conserva.

Trazabilidad de resultados

Fuentes aceptadas: professor_metrics_v1; vae_test_reconstruction_scored_v1; ubc_ocean_mil_test_scored_v1; tissue_test_scored_v1; la PCA espacial fija de frozen_vae_rotation_orbits; Kaggle maximshtefan/eqvae-corrected-rotation-geometry/1; y Kaggle maximshtefan/eqvae-decoded-latent-transform-audit/1. Para Spec 0050, el resumen geométrico tiene SHA-256 aab68ca5b7cbe989ea1cd79740a64d83784441f85ffde09a6ee6ebebe7faf43c y el addendum ec74b37f509205bca12294321844a3cfb48dbd2f1763c8ff94290fe064e86f94. Para Spec 0051, el resumen tiene SHA-256 616e3a6c9caa6b8e72a0b21f41a5121d7a5baa420f8023b35775fedaf252a754, el manifiesto a1168b419080305138f7aedca4c1ed345c3d5947e78299b0e5ea1430a75d3c50 y el addendum b0fa0cc2eebe1207fcc2da7a00c30b9b85c40f4353e332131423f76f6c380e34. El artefacto dense-rotation-population/1 se conserva sólo como procedencia supersedida. El informe no recalcula inferencia, cambia umbrales ni selecciona ejemplos.